



INFORME TÉCNICO: ANÁLISIS DISCRIMINANTE LINEAL (LDA) Y ANÁLISIS DISCRIMINANTE CUADRÁTICO (QDA)

Docente: Ing. Eleanor Varela Tapia, Msig. Mdges.

APRENDIZAJE AUTOMÁTICO



Facultad de Ciencias
Matemáticas y Físicas

CURSO:

CDDEIA-ELMA-4-1

ESTUDIANTE:

JEANPAUL DAVID ZAVALA BETANCOURT

7 DE JULIO DE 2026

Informe técnico de investigación

1. Introducción

1.1 ¿Qué es el análisis discriminante?

La técnica estadística multivariante conocida como análisis discriminante tiene como finalidad examinar y esclarecer las diferencias que existen entre dos o más grupos de personas u objetos, los cuales han sido definidos con anterioridad. Esto se realiza mediante un conjunto de variables que se miden simultáneamente en ellos. Es posible comprenderlo desde dos perspectivas complementarias: como una técnica de dependencia, ya que establece un modelo de causalidad en el cual la variable a explicar es categórica (la pertenencia a un grupo), mientras que las variables explicativas tienen una naturaleza métrica o continua; y como método de clasificación, ya que facilita entender por qué diferentes sujetos se vinculan con diversos niveles de un factor, y a partir de eso elaborar reglas que posibiliten la asignación de nuevas observaciones a una de las categorías existentes (Universidad de Costa Rica, s. f.; Universidad de Chile, s. f.).

En términos prácticos, el análisis discriminante se puede caracterizar como una forma particular de un modelo de regresión en la que la variable dependiente es categórica (la etiqueta del grupo) y las independientes son continuas, las cuales definen a qué grupo corresponde cada observación (Universidad de Alicante, s. f.).

Desde el punto de vista del aprendizaje automático, el análisis cuadrático y discriminante lineal son clasificadores generativos. En vez de modelar directamente la frontera entre clases, estos modelan la distribución de probabilidad de las variables predictivas en cada clase (que suele ser una distribución normal multivariante) y, a través del teorema de Bayes, calculan la probabilidad de pertenencia a cada clase dada una serie de observaciones (mlweb.loria.fr, s. f.).

1.2 ¿Cuál es el objetivo de un modelo discriminante?

El análisis discriminante puede tener dos metas que no se excluyen mutuamente. El primero es de carácter descriptivo: consiste en describir el perfil de los grupos existentes, determinando qué variables contribuyen a distinguirlos y cómo lo hacen; por ejemplo, caracterizar a los compradores frente a los que no compran un producto (Universidad de Costa Rica, s. f.). El segundo es predictivo: establecer, con base en los datos existentes, una función o regla de clasificación que posibilite la asignación de un nuevo individuo (del que se tienen las variables

predictivas, pero no el grupo al cual pertenece) a alguna de las categorías previamente definidas. El reconocimiento de patrones, la evaluación del riesgo crediticio o el diagnóstico clínico son áreas de aplicación que hacen que este segundo objetivo sea el más importante (Vinculando, 2014).

En resumen, un modelo discriminante tiene como objetivo buscar la combinación de variables predictivas que maximice el distanciamiento entre las distintas clases y minimice la dispersión al interior de cada una de ellas. Esto se hace con el fin de que los datos observados en un mismo grupo estén lo más cerca posible entre sí y lo más lejos posible de las observaciones de otros grupos (Analytics Vidhya, 2024).

1.3 ¿Qué diferencia existe entre clasificación y regresión?

La diferencia principal entre clasificación y regresión está en la clase de variable dependiente o de salida. En un problema de regresión, la variable que se busca predecir es continua o cuantitativa (como el ingreso de una familia o el precio de una casa) y la meta del modelo es calcular un valor numérico que esté lo más próximo posible al valor real. Por otro lado, en un problema de clasificación, la variable que se desea predecir es categórica o discreta, lo que significa que representa la pertenencia a una categoría o clase —por ejemplo, "enfermo/sano" o "aprobado/reprobado"— y el propósito del modelo consiste en asignar cada observación a su respectiva categoría (StudySmarter, s. f.).

Los métodos de clasificación son, en efecto, el análisis discriminante lineal y cuadrático: aunque su funcionamiento interno consiste en crear funciones que son combinaciones cuadráticas o lineales de las variables predictoras (de manera parecida a lo que haría un modelo de regresión), la salida final no es un valor numérico continuo. En vez de eso, se asigna cada observación a una de las clases posibles. Esto se hace comúnmente mediante la comparación entre probabilidades posteriores o distancias (como la distancia Mahalanobis) entre el centroide de cada grupo y la observación (scikit-learn, s. f.).

2. Análisis Discriminante Lineal (LDA)

2.1 ¿Qué es el Análisis Discriminante Lineal (LDA)?

El Análisis Discriminante Lineal es una ampliación del discriminante lineal de Fisher, que Ronald Fisher planteó en 1936 con el objetivo de distinguir dos tipos de iris a partir de mediciones morfológicas (Analytics Vidhya, 2024). LDA es un procedimiento de clasificación generativa que tiene como suposiciones que las observaciones de cada categoría surgen de una

distribución normal multivariante y que la matriz de covarianza es la misma para todas las clases. En estas condiciones, el clasificador óptimo de Bayes se convierte en una función lineal de las variables predictivas (mlweb.loria.fr, s. f.). Según Wikipedia (2023), LDA se emplea, además de para clasificar, como método para reducir la dimensionalidad. Esto se lleva a cabo proyectando los datos originales en un subespacio de dimensión reducida que está compuesto por las direcciones que separan mejor las clases, antes de aplicar una clasificación posterior.

2.2 Supuestos estadísticos de LDA

LDA se basa en un conjunto de hipótesis que, si se satisfacen de manera razonable, aseguran que el clasificador se acerque al clasificador óptimo de Bayes:

Normalidad multivariante: Se supone que las variables predictivas de cada clase siguen una distribución normal multivariante (Analytics Vidhya, 2024).

Homogeneidad de covarianzas y varianzas (homocedasticidad): Independientemente de que las medias puedan ser diferentes, todas las clases comparten la misma matriz de covarianza Σ (STAT 897D, s. f.).

Independencia de las observaciones: Las instancias que forman parte de la muestra deben ser independientes unas de otras.

Una condición necesaria para estimar los parámetros del modelo es que no exista una multicolinealidad severa entre las variables predictoras y que la cantidad de estas sea menor al número de observaciones disponibles (Fundamentos de Ciencia de Datos con R, s. f.).

2.3 ¿Qué significa que las clases compartan la misma matriz de covarianza?

Que las clases compartan la misma matriz de covarianza significa que, aunque cada clase k tiene su propio vector de medias μ_k (es decir, su propio "centro" en el espacio de las variables predictoras), la forma, orientación y dispersión de la nube de puntos alrededor de ese centro — capturada precisamente por la matriz de covarianza Σ_k — se asume idéntica para todas las clases: $\Sigma_1 = \Sigma_2 = \dots \Sigma_k = \Sigma$ (arxiv.org/1906.02590, s. f.). Geométricamente, esto equivale a decir que las elipses (o elipsoides, en más de dos dimensiones) que describen la dispersión de cada clase tienen el mismo tamaño y la misma orientación, y solo están desplazadas en el espacio según la

ubicación de su media (scikit-learn, s. f.).

Esta hipótesis de homocedasticidad simplifica considerablemente el problema de estimación, porque en vez de calcular una matriz de covarianza diferente para cada clase, es suficiente con calcular solamente una matriz de covarianza combinada (también conocida como "pooled" o agrupada), que generalmente se obtiene al promediar las matrices de covarianza muestrales de cada clase.

2.4 ¿Cómo construye la función discriminante?

LDA, desde la perspectiva generativa o probabilística, describe la densidad de cada clase k como una normal multivariante con media μ_k y matriz de covarianza común Σ . Según el teorema de Bayes, la probabilidad a posteriori de que una observación x sea parte de la clase k está en proporción con el producto entre la densidad y la probabilidad a priori π_k . Si se toma el logaritmo de esa probabilidad y se suprimen los términos independientes de k (debido a que son comunes a todas las clases, pues Σ es igual para todas), se genera una función discriminante lineal que tiene la siguiente estructura:

$$\delta_k(x) = \log(\pi_k) + x^T \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k$$

arxiv.org/2310.11470, s. f. Se le asigna la observación x a la clase cuyo valor de $\delta_k(x)$ sea el más alto.

LDA puede ser descrito, de manera equivalente, como un clasificador que, después de "blanquear" o normalizar los datos para transformar la matriz de covarianza común en la identidad, asigna a cada observación aquella clase cuya media se encuentre más próxima en términos de distancia euclídea, corrigiendo esta última por las probabilidades previas de cada clase (scikit-learn, s. f.). La distancia de Mahalanobis es el término que se utiliza para referirse a este concepto de cercanía corregido por la covarianza.

2.5 ¿Por qué la frontera de decisión es lineal?

El umbral de decisión entre dos clases, j y k , consiste en el conjunto de puntos x para los que $\delta_k(x) = \delta_j(x)$. Cuando se sustraen las dos funciones discriminantes, los términos cuadráticos en x —los cuales vienen de $x^T \Sigma^{-1} x$ — se eliminan completamente debido a que la matriz Σ^{-1} es idéntica en las dos expresiones, y solo queda una combinación lineal de x igualada con una constante (arxiv.org/1906.02590, s. f.). Por lo tanto, el hiperplano es la frontera resultante: una

línea recta en dos dimensiones, un plano en tres dimensiones y un hiperplano cuando se trata de dimensiones más altas. Es específicamente esta anulación de los términos cuadráticos, que solo es factible por medio de la hipótesis de covarianza compartida, la que le da el nombre al método: análisis discriminante "lineal".

2.6 Ventajas de LDA

Su solución no es iterativa y resulta computacionalmente económica, ya que solo necesita calcular proporciones, medias y una sola inversión de matriz (mlweb.loria.fr, s. f.).

Su uso es más sencillo porque no tiene hiperparámetros que se deben ajustar a través de la validación cruzada (scikit-learn, s. f.).

Al calcular un número limitado de parámetros (solamente una matriz de covarianza), tiene poca varianza y funciona adecuadamente, incluso con conjuntos de datos más o menos pequeños (ethanwicker.com, 2021).

Es interpretativa: la función discriminante lineal permite comprender qué variables tienen mayor incidencia en la separación de grupos.

Se puede utilizar simultáneamente como un método para reducir la dimensionalidad, proyectando los datos en las direcciones que ofrecen mayor discriminación (Wikipedia, 2023).

No solamente en problemas binarios, sino también en problemas multiclase (scikit-learn, s. f.), opera de manera natural.

2.7 Limitaciones de LDA

El LDA puede verse afectado por un sesgo alto si el supuesto de igualdad de covarianzas entre las clases no se cumple en la práctica, dado que la frontera lineal no logra captar la forma real de la relación entre las clases (ethanwicker.com, 2021).

Es susceptible a valores atípicos, que tienen el potencial de alterar la matriz de covarianza agrupada y los promedios.

Cuando el número de variables predictoras es muy elevado en comparación con la cantidad de observaciones, su rendimiento se deteriora, ya que la matriz de covarianza puede llegar a estar mal condicionada o ser casi singular (arxiv.org/2401.17760, s. f.).

La calidad de la clasificación puede disminuir si las distribuciones se alejan demasiado de ser normales; esto depende de la normalidad multivariante de los datos.

2.8 ¿En qué problemas suele utilizarse LDA?

LDA se usa principalmente en el reconocimiento de patrones y facial, donde se utiliza para disminuir una gran cantidad de valores de píxeles a un conjunto más manejable de rasgos antes del proceso de clasificación (Wikipedia, 2023). Es común también en bioestadística y medicina, para crear funciones que categoricen la gravedad de una enfermedad (severa, moderada o leve) basándose en variables clínicas y de laboratorio; en biología, para distinguir cepas o especies a partir de evaluaciones espectrales; en el sector financiero, para estimar el riesgo de impago o morosidad de un cliente; y en bioinformática y minería de texto. (2021, ethanwicker.com; 2023, Wikipedia).

3. Análisis Discriminante Cuadrático (QDA)

3.1 ¿Qué es el análisis discriminante cuadrático?

El Análisis Discriminante Cuadrático es una ampliación lógica de LDA, ya que mantiene el mismo marco probabilístico (cada clase se modela a través de una distribución normal multivariante), pero suprime la presunción de que todas las clases tienen la misma matriz de covarianza. En lugar de eso, QDA calcula una matriz de covarianza Σ_k específica para cada clase k (scikit-learn, s. f.). Esta diferencia, que parece ser pequeña, tiene un impacto significativo: si los términos cuadráticos no se eliminan cuando se comparan dos clases, la función y la frontera de decisión resultantes son cuadráticas y no lineales, lo que explica su nombre.

3.2 Supuestos de QDA

Igual que LDA, supone que las observaciones de cada clase obedecen a una distribución normal multivariante.

En contraposición a LDA, no presupone que las matrices de covarianza sean iguales entre clases: es posible que cada clase tenga su propia forma, dispersión y orientación (GeeksforGeeks, 2025).

Es necesario que en cada clase haya suficientes observaciones para poder calcular con fiabilidad su propia matriz de covarianza; el volumen de observaciones por clase tiene que ser considerablemente superior al de variables predictoras.

Como ocurre en LDA, se supone que las observaciones son independientes entre sí.

3.3 ¿Por qué cada clase posee una matriz de covarianza distinta?

En QDA, cada clase k tiene su matriz de covarianza Σ_k , dado que en numerosos fenómenos reales no hay motivos para creer que la dispersión y la forma de la nube de puntos de una clase sean las mismas que las de otra. Por ejemplo, una clase puede tener una correlación diferente entre pares de variables o mostrar una variabilidad mucho más amplia en una variable que en otra. QDA puede describir de manera más precisa la estructura real de cada grupo al estimar una matriz de covarianza específica para cada clase, generalmente usando la matriz de covarianza muestral de las observaciones que pertenecen a esa misma clase. Sin embargo, esto conlleva calcular más parámetros a partir de los datos (scikit-learn, s. f.).

3.4 ¿Por qué la frontera es cuadrática?

Los términos que incluyen $x^T \Sigma_k^{-1} x$ ya no se eliminan cuando se comparan dos clases diferentes, debido a que cada una tiene su propia matriz Σ_k^{-1} (arxiv.org/2310.11470, s. f.), si bien la función discriminante logarítmica para QDA se deriva de la misma manera que para LDA. Como resultado, la función discriminante mantiene los términos de segundo grado en x y la frontera de decisión que está establecida por $\delta_k(x) = \delta_j(x)$ se convierte en una superficie o curva cuadrática (una parábola, una elipse, una hipérbola o sus contrapartes multivariantes en dimensiones más altas), en vez de ser un hiperplano (scikit-learn, s. f.).

3.5 Ventajas de QDA frente a LDA

Es considerablemente más adaptable: tiene la capacidad de ajustarse mejor a las relaciones no lineales entre clases, ya que permite límites curvos (scikit-learn, s. f., versión 0.15).

Cuando el supuesto de la igualdad de covarianzas en LDA no se da en la práctica, QDA es capaz de minimizar el sesgo del modelo y puede lograr una clasificación más exacta (ethanwicker.com, 2021).

Mantiene las ventajas de LDA, como la solución cerrada y la falta de hiperparámetros que se

deban ajustar.

Es preferible cuando se cuenta con conjuntos de datos extensos, porque en esas circunstancias disminuir la varianza del modelo —que es el principal punto fuerte de LDA— tiene menos prioridad que reducir el sesgo (ethanwicker.com, 2021).

3.6 Desventajas de QDA

Cuando se calcula una matriz de covarianza diferente para cada clase, el total de parámetros a estimar crece significativamente en proporción con la cantidad de clases y variables. Esto provoca que aumente la varianza del modelo y también el peligro de sobreajuste, particularmente si hay pocas observaciones por cada clase (ethanwicker.com, 2021).

Para generar estimaciones estables de las matrices de covarianza, necesita más observaciones por clase que LDA (arxiv.org/1705.02826, s. f.).

Es un poco más costoso en términos computacionales que LDA, ya que exige calcular e invertir una matriz de covarianza por cada clase.

Pierde un poco de interpretabilidad en comparación con LDA, porque la relación entre las variables predictoras y la clasificación ya no es una mera combinación lineal.

3.7 ¿Qué tipo de conjuntos de datos favorecen el uso de QDA?

QDA es particularmente apropiado cuando hay evidencia, ya sea teórica o empírica, de que las diferentes clases tienen estructuras de covarianza que se distinguen claramente, lo que significa que la dispersión, la orientación o la correlación entre las variables varían de un grupo a otro. Además, debe contarse con un número suficientemente elevado de observaciones por cada clase para poder estimar cada matriz de covarianza con fiabilidad (scikit-learn, s. f.). Cuando los análisis previos de los datos (por ejemplo, a través de gráficos de dispersión o elipses de covarianza) indican que las fronteras naturales entre las clases no son rectas, sino curvilíneas, esta también es una opción sensata.

4. Comparación entre LDA y QDA

La siguiente tabla resume las principales diferencias entre ambos métodos, discutidas en las secciones anteriores:

Criterio	LDA	QDA
Matriz de covarianza	Una sola matriz compartida por todas las clases (Σ)	Una matriz distinta por cada clase (Σ_k)
Frontera de decisión	Lineal (hiperplano)	Cuadrática (curva o superficie de segundo orden)
N.º de parámetros a estimar	Menor: una matriz de covarianza para todo el modelo	Mayor: una matriz de covarianza por clase
Sesgo / varianza	Mayor sesgo, menor varianza	Menor sesgo, mayor varianza
Tamaño muestral requerido	Funciona bien con pocas observaciones	Requiere muestras más grandes por clase
Flexibilidad	Baja: solo captura relaciones lineales	Alta: captura relaciones no lineales entre clases
Riesgo de sobreajuste	Bajo	Más alto, especialmente en alta dimensión
Uso típico	Reducción de dimensionalidad, reconocimiento facial, bioestadística, texto	Clasificación con fronteras curvas, diagnóstico médico, finanzas

Finalmente, la decisión entre LDA y QDA es una expresión clásica del compromiso entre la varianza y el sesgo (bias-variance trade-off): LDA, como es menos versátil, suele producir modelos con un sesgo más alto y una varianza más baja; en cambio, QDA, al ser más flexible, tiende a disminuir el sesgo a expensas de aumentar la varianza (ethanwicker.com, 2021).

5. Conclusiones

El análisis discriminante, tanto en su versión cuadrática como en la lineal, es un conjunto de técnicas de clasificación generativas que se basan en el teorema de Bayes y en la teoría probabilística. LDA y QDA se asemejan en la suposición de que cada clase tiene una normalidad multivariante, pero difieren únicamente en que las matrices de covarianza son iguales o no entre clases. Esto influye tanto en el equilibrio entre sesgo y varianza del modelo final como en la forma de la frontera de decisión (cuadrática o lineal).

Cuando los datos son escasos, cuando se puede asumir que las clases tienen una estructura de dispersión parecida o cuando es importante reducir la dimensionalidad y tener interpretabilidad, LDA es más conveniente. Por el contrario, QDA es más apropiado cuando hay suficientes observaciones por clase y cuando las clases tienen estructuras de covarianza claramente diferentes. Esto permite captar relaciones no lineales que LDA no podría representar.

La comparación empírica de ambas técnicas, empleando datos reales y aplicándolas en Python (por ejemplo, con las clases `LinearDiscriminantAnalysis` y `QuadraticDiscriminantAnalysis` de `scikit-learn`), permite la posibilidad de validar estas consideraciones teóricas en la práctica y elegir el modelo más adecuado dependiendo del problema concreto.

Referencias

- Analytics Vidhya (2024). *A Brief Introduction to Linear Discriminant Analysis*. Recuperado de <https://www.analyticsvidhya.com/blog/2021/08/a-brief-introduction-to-linear-discriminant-analysis/>
- GeeksforGeeks (2025). *Linear and Quadratic Discriminant Analysis using Sklearn*. Recuperado de <https://www.geeksforgeeks.org/machine-learning/linear-and-quadratic-discriminant-analysis-using-sklearn/>
- Mahadi, M., Ballal, T., Moinuddin, M., Al-Naffouri, T. Y., & Al-Sagga, U. M. (2024). Regularized Linear Discriminant Analysis Using a Nonlinear Covariance Matrix Estimator. *arXiv:2401.17760*.
- mlweb.loria.fr (s.f.). *Linear and Quadratic Discriminant Analysis (LDA/QDA)*. Recuperado de <https://mlweb.loria.fr/book/en/lda.html>
- Pennsylvania State University, STAT 897D (s.f.). 9.2.2 - *Linear Discriminant Analysis*. Recuperado de <https://online.stat.psu.edu/stat857/node/74/>
- scikit-learn developers (s.f.). 1.2. *Linear and Quadratic Discriminant Analysis*. Recuperado de https://scikit-learn.org/stable/modules/lda_qda.html
- scikit-learn developers (s.f.). *Linear and Quadratic Discriminant Analysis with covariance ellipsoid*. Recuperado de https://scikit-learn.org/stable/auto_examples/classification/plot_lda_qda.html
- Universidad de Alicante (s.f.). *Análisis Discriminante*. Recuperado de https://www.estadistica.net/MasterEconometria/Analisis_Discriminante.pdf
- Universidad de Chile, IN540 (s.f.). *Análisis Discriminante* [material de curso]. Recuperado de https://www.ucursos.cl/ingenieria/2010/1/IN540/1/material_docente/bajar?id=285459&bajar=1
- Universidad de Costa Rica, INEC (s.f.). *Análisis Discriminante: Definición*. Recuperado de https://inec.cr/wwwisis/documentos/Otros_doc/discriminante.pdf
- X|Wicker, E. (2021). *Quadratic Discriminant Analysis*. Recuperado de <https://ethanwicker.com/2021-02-10-quadratic-discriminant-analysis-001/>
- Wikipedia (2023). *Análisis discriminante lineal*. Recuperado de https://es.wikipedia.org/wiki/An%C3%A1lisis_discriminante_lineal